
Exploração de um espaço 2D gerado pelas ativações de uma *Bottleneck Layer* no conjunto MNIST

João Henrique Monchelato dos Santos - 769730
Marcelo Itonaga Sato - 758580

Departamento de Computação, Universidade Federal de São Carlos

1 Resumo

A utilização do conjunto de dados MNIST para iniciar o estudo de CNNs é amplamente difundida, no entanto, poucos estudos procuram entender qual o funcionamento das ativações realizadas pelas camadas ocultas existentes em redes neurais de qualquer tipo. Neste trabalho, um modelo de CNN contendo uma camada gargalo de dois atributos foi utilizado para o treinamento de classificação dos dígitos do conjunto, sendo possível treinar o modelo e visualizar as ativações em um espaço 2D da camada gargalo. Com uma acurácia acima de 70%, obteve-se informações importantes quanto as características dos numerais identificados em cada região desse espaço, além de propor o entendimento do significado dos eixos x e y para o contexto e identificar quais numerais foram melhor identificados e separados no espaço.

2 Introdução

As Redes Neurais Convolucionais (Convolutional Neural Networks (CNNs)) ganharam enorme importância na área de Visão Computacional nos últimos anos por serem muito eficientes nas tarefas de detecção de objetos, classificação e segmentação de imagens [1, 2]. Para as tarefas de classificação, essas redes são capazes de extrair características de uma imagem de entrada utilizando convoluções e funções de ativações ao longo das suas camadas ocultas e retornar uma classe, de acordo com o problema a qual está sendo trabalhado.

O conjunto de dados MNIST é um dos mais utilizados para o estudo de redes neurais convolucionais e um importante ponto de partida para os indivíduos em seu primeiro contato com esse tipo de rede neural. Em razão de sua simplicidade, contando com imagens de 28x28 pixels em escala de cinza, o conjunto é o ideal para uma primeira compreensão e experimentação de algoritmos de CNNs.

Pelo fato do conjunto MNIST ser amplamente utilizado, tendo diversos modelos já treinados nele e com precisões indiscutíveis, o dataset funciona como *benchmark* de outros estudos da literatura. No entanto, em muitas aplicações as CNNs são utilizadas estritamente como uma função desconhecida que mapeia uma imagem de entrada em uma categoria de rótulos. Em razão disso, visualizar os atributos que são gerados pelas ativações do modelo é de extrema importância para melhor entendimento das características da rede neural, principalmente quando há um gargalo em alguma das camadas do modelo.

Uma *Bottleneck Layer* pode ser representada como uma camada onde seu número de atributos é relativamente inferior ao número de classes desejadas para a classificação, ocorrendo então uma perda de informação durante o aprendizado e impactos na precisão do modelo, no entanto, quando essa camada gargalo é de apenas 2 atributos, existe a possibilidade de visualizar as ativações desta *hidden layer* em um espaço 2D, realizando análises quanto às propriedades mais relevantes para classificação dos numerais.

Diante deste contexto, foi criado um modelo de CNN para classificação dos 10 dígitos do conjunto de dados MNIST, contendo uma camada gargalo com apenas 2 atributos, sendo essa camada decisiva para a camada de saída com dimensão 10 (número de classes a serem classificadas). O artigo tem a motivação de identificar e analisar o espaço 2D que será gerado pelas ativações geradas por essa camada, interpretando quais são as características dos dígitos em cada região do espaço, identificando as propriedades mais relevantes dos eixos x e y e as classes que foram melhor classificadas e segregadas do restante do conjunto.

3 Objetivos

O objetivo principal deste artigo é investigar as ativações de uma camada gargalo de dois atributos no treinamento do conjunto de dados MNIST, extraíndo as seguintes conclusões sobre o espaço 2D obtido:

1. Quais imagens se localizam em cada um dos quatro cantos;
2. Interpretação do significado dos eixos x e y ;
3. Classes que ficaram mais separadas.

4 Metodologia

4.1 Modelo de Rede Neural utilizado

A arquitetura da CNN utilizada para este trabalho é composto de três camadas de convolução em sequência, utilizando a função de ativação ReLU. Após as camadas de convolução, o modelo passa por duas camadas lineares, a primeira, a qual é objetivo deste estudo, é uma camada gargalo, pois ela contém apenas dois atributos, enquanto a última, responsável pela classificação das imagens que passam pelo modelo, contém 10 atributos, referentes ao dígito de cada classe que pode ser inferida pela rede. O código de definição do modelo é o seguinte:

```

1  class Model(nn.Module):
2  def __init__(self):
3      super().__init__()
4
5      self.convs = nn.Sequential(
6          nn.Conv2d(1, 16, kernel_size=3, padding=2),
7          nn.ReLU(),
8          nn.Conv2d(16, 16, kernel_size=3, padding=2),
9          nn.ReLU(),
10         nn.Conv2d(16, 16, kernel_size=3, padding=2)
11     )
12
13     self.pool = nn.AdaptiveMaxPool2d(1)
14     self.fc1 = nn.Linear(16, 2)
15     self.fc2 = nn.Linear(2, 10)
16
17     def forward(self, x):
18         x = self.convs(x)
19         x = self.pool(x)
20         x = x.reshape(x.shape[0], -1)
21         x = self.fc1(x)
22         x = self.fc2(x)
23
24     return x

```

O treinamento da rede foi realizado através de um script *train.py* e feito em 2 etapas, a primeira, com um *learning rate* de 0.05 e por 35 épocas, posteriormente, o modelo foi treinado novamente por mais 20 épocas e com um *learning rate* de 0.0001.

Com o modelo treinado, foi possível visualizar as ativações em um espaço 2D, capturando quais são as ativações específicas da camada gargalo. É possível executar este processo transformando a última camada do modelo em uma camada identidade. Com a última camada sendo uma camada identidade, ao aplicar uma imagem no modelo, as ativações da última camada não acontecem, sendo assim, os valores obtidos como saída da aplicação são as próprias ativações da camada gargalo, obtendo um tensor com dimensão $[n, 2]$, onde n é o número de imagens que passaram pelo modelo, e cada imagem possui as 2 ativações da camada gargalo.

Para viabilização do método, foi implementada a função *get_2d_activations*, a qual realiza as operações descritas no parágrafo anterior e é mostrada a seguir:

```
1 def get_2d_activations(model, dataset):
2     data = torch.stack([img for img, _ in dataset])
3     target = [target for _, target in dataset]
4     model.eval()
5     model.fc2 = nn.Identity()
6
7     with torch.no_grad():
8         activations = model(data)
9         labels = target
10
11     return activations, labels
```

A função recebe o modelo e o *dataset* desejado para analisar as ativações, neste caso, o *dataset* é o mesmo usado para treinamento da rede neural. Dentro da função, as imagens do conjunto são agrupadas em um novo tensor e suas classes são atribuídas à uma lista. Em seguida, o modelo é colocado em modo de validação e na linha 5 é realizada a operação de transformar a última camada do modelo em uma camada identidade.

Os dados são então aplicados ao modelo e as ativações que a variável *activations* recebe já são as ativações da camada gargalo. A variável *labels* recebe os *targets* para que seja possível criar um *colormap* para identificação das classes no momento do *plot* das ativações.

Ao final, é possível visualizar o posicionamento de cada classe no espaço 2D com o código a seguir que efetua o processo:

```
1 activations, labels = get_2d_activations(model, ds_train)
2
3 plt.figure(figsize=(10, 8))
4 scatter = plt.scatter(activations[:, 0], activations[:, 1],
5 c=labels, cmap='tab10', alpha=0.5)
6 plt.colorbar(scatter, ticks=range(10))
7 plt.xlabel('Eixo-X')
8 plt.ylabel('Eixo-Y')
9 plt.title('Ativacoes 2D do Modelo no Conjunto de Treinamento MNIST')
10 plt.show()
```

O notebook com as análises e os *scripts* utilizados no trabalho podem ser acessados no repositório do *GitHub*¹.


5 Resultados

Nesta seção são discutidos os resultados obtidos, separando uma seção para interpretação dos resultados de treinamento, e outra seção para interpretação do espaço 2D formado pelas ativações.

5.1 Treinamento


Para o treinamento foi utilizada a estratégia de dividi-lo em 2 modelos, o primeiro com um *learning rate* maior, a fim de um aprendizado mais acelerado e que resultou em uma acurácia de 64% (Figura 1) neste primeiro momento. Após isso, foi realizado um novo treinamento, com um *learning rate* menor para um aprimoramento do aprendizado, atingindo a acurácia final de 71% (Figura 2), a qual além do alto resultado na precisão, o resultado visual de divisão das classes no gráfico também foi satisfatório.

Figura 1: Loss de treinamento/validação e acurácia do modelo (35 épocas).



¹<https://github.com/jhmonchelato/analise-espaco-2d-MNIST>


Figura 2: Loss de treinamento/validação e acurácia do modelo (55 épocas, 35 + 20).



5.2 Análise do espaço 2D

O espaço 2D obtido foi satisfatório, com uma divisão visual relevante em relação ao agrupamento de cada classe, demonstrada no gráfico representado na figura 3:

Figura 3: Ativações 2D da camada gargalo do modelo no Conjunto MNIST.



5.2.1 Distribuição espacial das classes

Em relação a como os números ficaram distribuídos no espaço, é perceptível que o canto superior esquerdo ficou mais concentrado de dígitos predominantemente com formas retas, como o 1, 4 e 7. No canto superior direito ficaram concentrados os números 3, 5 e um porção do 2, números mais arredondados e com algum traço reto. O canto inferior direito ficou caracterizado em sua maioria pelo número 8, em razão de sua forma única composta de 2 círculos, além de uma porção do número 6. No canto inferior esquerdo ficou o número 0, também pela sua forma única simples de apenas um círculo. O número 9 ficou mais centrali-

zado, com uma porção em cada região do plano.

5.2.2 Interpretação dos significados dos eixos x e y

A interpretação dos eixos pode ser feita da seguinte forma, o eixo x pode ser interpretado como o tipo de curvatura dos número, mais a esquerda estão localizado número compostos de formas retas, como o 1, 4 e 7. Mais a direita ficam os número com formas curvas mais complexas, como o 8, 5 e 3. No centro ficaram mesclados números com formas curvas e retas, como o 2 e números com formas curvas mais simples, como o 6, 9 e 0 além de uma pequena parte do 8.

O eixo y parece capturar a densidade de pixels das imagens de cada número, com a parte superior possuindo números com área menor, ou seja, com alta concentração de pixels em sua região, levando a maior densidade, como ocorre nos números 7, 2 e 3, enquanto os números 0, 6 e 8 da região inferior possuem pixels distribuídos em uma região maior, levando a área e, por consequência, densidade menores.

5.2.3 Separação das classes

A classe representante do número 1 é notavelmente a mais distinta das demais, o 7 e o 4 também não possuem sobreposições relevantes, exceto entre si, mostrando a capacidade do modelo em identificar formas retas e mais simples. A forma de dois círculos um em cima do outro presente no 8 também consegue ser bem diferenciada pelo modelo. Formas mais complexas como 2 e 3 já possuem mais sobreposição, com os números 9 e 5 sendo os mais sobrepostos visualmente, muito por conta de suas formas parecidas, pois o número 5 é similar ao 9 caso seja retirado seu traço superior direito.

6 Conclusões

O presente trabalho buscou explorar a representação de dados em um espaço 2D utilizando uma arquitetura de rede neural convolucional com uma camada gargalo de duas dimensões, aplicado ao conjunto de dados MNIST. A visualização das ativações da camada de *bottleneck* proporcionou uma análise qualitativa da

separabilidade das diferentes classes de dígitos, oferecendo informações sobre as capacidades e limitações do modelo no reconhecimento de padrões.

Com os resultados obtidos, conclui-se que o modelo de CNN com camada gargalo estudado, apesar da perda de informação, pode levar a resultados satisfatórios, não apenas obtendo precisão levemente acima de 70%, mas também classificando os dados dos números do *dataset* MNIST com o uso de apenas dois atributos que fornecem muita informação sobre o conjunto de dados após serem estudados, sendo eles a curvatura e densidade do número classificado, mostrando que a perda de informação resultante da redução de dimensionalidade não impossibilita a obtenção de informações relevantes para classificação dos dígitos.

Referências

- [1] Waseem Rawat and Zenghui Wang. Deep convolutional neural networks for image classification: A comprehensive review. *Neural Computation*, 29(9):2352–2449, 2017.
- [2] Leiyu Chen, Shaobo Li, Qiang Bai, Jing Yang, Sanlong Jiang, and Yanming Miao. Review of image classification algorithms based on convolutional neural networks. *Remote Sensing*, 13(22), 2021.